

CIFAKE — Real vs AI-Generated Image Detection

Αναφορά: Κλασικοί Αλγόριθμοι, Νευρωνικά Δίκτυα, Transfer/Few-Shot Learning, Self-Supervised Learning & LoRA

Όλα τα αριθμητικά αποτελέσματα προέρχονται από εκτέλεση σε υποσύνολο 10.000 εικόνων (5.000 ανά κλάση) με stratified split 70/15/15 (7.000 / 1.500 / 1.500 εικόνες). Τα νούμερα και οι εικόνες αντιστοιχούν στην τελική εκτέλεση του notebook, συμπεριλαμβανομένου του LoRA fine-tuning.

1. Περιγραφή του Dataset


Το **CIFAKE** είναι dataset δυαδικής ταξινόμησης για ανίχνευση εικόνων παραγόμενων από AI. Περιέχει 120.000 εικόνες 32×32 RGB: 60.000 **πραγματικές (REAL)** από το CIFAR-10 και 60.000 **συνθετικές (FAKE)** παραγόμενες με latent diffusion (Stable Diffusion v1.4). Το πλήρες dataset χωρίζεται σε 100.000 train και 20.000 test, με τέλεια ισορροπία κλάσεων.

Χρησιμοποιήθηκε **ισορροπημένο υποσύνολο 10.000 εικόνων** για υπολογιστική διαχειρισσιμότητα. Το imbalance ratio είναι **1.0** (απόλυτη ισορροπία) — δεν απαιτείται καμία τεχνική αντιμετώπισης ανισορροπίας.


Η **βασική πρόκληση** δεν είναι η αναγνώριση του αντικείμενου (real και fake μοιράζονται τις ίδιες κατηγορίες CIFAR-10), αλλά ο εντοπισμός **λεπτών generative artifacts**: σε ανάλυση 32×32 το διακριτικό σήμα κρύβεται σε υφές υψηλής συχνότητας και μικρές ασυνέπειες (συχνά στο background), όχι στο κύριο αντικείμενο — γεγονός που ευνοεί τις βαθιές αναπαραστάσεις έναντι των χειροποίητων.

EDA — Βασικά ευρήματα

- Κατανομή κλάσεων: 5.000 / 5.000 (ισορροπημένο). Διαστάσεις: ομοιόμορφα 32×32 RGB.
- Τα ιστογράμματα pixel intensity ανά κλάση είναι σε γενικές γραμμές παρόμοια — απλά global χαρακτηριστικά φωτεινότητας δεν διαχωρίζουν εύκολα real/fake, υποδεικνύοντας ότι το σήμα είναι τοπικό/δομικό.
- Διαστάσεις feature vectors: HOG 1764, LBP 10, Color (RGB+HSV) 192, CNN (ResNet18) 512. Πριν τους κλασικούς ταξινομητές εφαρμόστηκε PCA σε 150 διαστάσεις.



Εικ. 1 — Δείγματα εικόνων ανά κλάση (FAKE / REAL).




Εικ. 2 — Ιστογράμματα pixel intensity ανά κλάση.

2. Ερωτήσεις Ενότητας 0 (EDA & Features)

Q0.1 — Περιγραφή & ανισορροπία. Δυαδικό (REAL/FAKE), απόλυτα ισορροπημένο (1:1). Το accuracy είναι αξιόπιστη μετρική· αναφέρουμε επιπλέον **F1-macro** και **confusion matrix** για να φανεί αν κάποια κατεύθυνση λάθους κυριαρχεί. Δεν χρειάστηκε oversampling/undersampling ή class weights.

Q0.2 — Σύγκριση 2D visualizations. Στα PCA/t-SNE/UMAP, τα **CNN features** δίνουν σαφώς τον καλύτερο διαχωρισμό, ενώ τα HOG και LBP εμφανίζουν έντονη επικάλυψη (σχήμα/υφή είναι κοινά μεταξύ real/fake). Τα Color histograms δίνουν ενδιάμεσο διαχωρισμό. Επιβεβαιώνεται ποσοτικά στην Ενότητα 1 (ίδιος ταξινομητής ~0.91 με CNN έναντι ~0.76 με το καλύτερο handcrafted).



Εικ. 3 — 2D προβολές (PCA / t-SNE / UMAP) για HOG, LBP, Color και CNN features.

Q0.3 — Τι συλλαμβάνει κάθε feature. HOG → δομή/ακμές, LBP → τοπική υφή, Color histograms → κατανομή χρωμάτων χωρίς χωρική πληροφορία. Είναι σταθερά/χειροποίητα και δεν προσαρμόζονται στο task. Το pretrained CNN έχει μάθει **ιεραρχικές αναπαραστάσεις** (ακμές → υφές → μέρη → αντικείμενα) με inductive bias κατάλληλο για εικόνες, οπότε τα 512-d embeddings είναι σημασιολογικά πλουσιότερα και πιο διακριτικά.

Q0.4 — Κανονικοποίηση. Handcrafted → **StandardScaler** (fit μόνο στο train) και **PCA σε 150 διαστάσεις** πριν τους κλασικούς ταξινομητές. Για CNN features η κανονικοποίηση εισόδου δεν είναι απαραίτητη (έχει γίνει ImageNet normalization)· z-score/L2 βοηθά αλγορίθμους βασισμένους σε αποστάσεις.

3. Κλασικοί Αλγόριθμοι Ταξινόμησης

Q1.1 — Συγκριτικός πίνακας

Για κάθε αλγόριθμο: ο καλύτερος handcrafted τύπος (HOG/LBP/Color) και τα CNN features.
Ροή: 5-fold CV στο train (PCA → 150), αξιολόγηση στο test. Baseline DummyClassifier = 0.500.


Αλγόριθμος	Feature	Best HP	Test Acc	F1-macro
k-NN	CNN	cosine, k=21	0.848	0.848
k-NN	Color (best HC)	cosine, k=21	0.746	0.745
Naive Bayes	CNN	BernoulliNB	0.762	0.762
Naive Bayes	HOG (best HC)	GaussianNB	0.697	0.697
Logistic Reg	CNN	C=0.01, l2	0.865	0.865
Logistic Reg	Color (best HC)	C=0.01, l2	0.739	0.738
SVM	CNN	C=100, rbf	0.906	0.906
SVM	HOG (best HC)	C=10, rbf	0.765	0.765
Decision Tree	CNN	depth=5, leaf=10	0.755	0.755
Decision Tree	Color (best HC)	depth=5, leaf=5	0.675	0.670

Καλύτερος handcrafted: HOG+SVM (0.765). **Καλύτερα CNN features:** SVM+CNN (0.906).

Πλήρης κατάταξη test accuracy: CNN → SVM 0.906 > LogReg 0.865 > k-NN 0.848 > DT 0.755.
HOG → SVM 0.765· Color → SVM 0.753· LBP → k-NN 0.693.

Q1.2 — Καλύτερος συνδυασμός & confusion matrix

Καλύτερος συνδυασμός: **SVM + CNN features (Test Acc 0.906, F1-macro 0.906)**. Το confusion matrix (2×2) δείχνει λάθη και στις δύο κατευθύνσεις: FAKE → REAL (πειστικά synthetic) και REAL → FAKE (θολές/θορυβώδεις πραγματικές εικόνες).



Εικ. 4 — Confusion matrix του καλύτερου συνδυασμού (SVM + CNN features).

Q1.3 — Πόσο επηρεάζουν τα features

Η αναπαράσταση κυριαρχεί έναντι του αλγορίθμου: ένας απλός **Logistic Regression σε CNN features (0.865)** ξεπερνά κατά πολύ έναν **SVM-rbf σε HOG (0.765)**. Καλή αναπαράσταση + απλό μοντέλο > φτωχή αναπαράσταση + πολύπλοκο μοντέλο.

Q1.4 — Error analysis (Task 1.2)

Εντοπίστηκαν **37 test εικόνες που ταξινομούνται λάθος από όλους** τους αλγορίθμους. Είναι κατά κανόνα **εγγενώς αμφίσημες** (σε 32×32 τα artifacts χάνονται), άρα φταίνει και η αναπαράσταση και τα δεδομένα. Προτάσεις: **frequency-domain (FFT/DCT)** και **noise-residual / SRM filters** που στοχεύουν τα ίχνη του generative μοντέλου. **Αυτή η ιδέα υλοποιήθηκε** ως Dual-Branch Artifact-Aware CNN (§9.7): πέτυχε 0.935, ισοφαρίζοντας το custom CNN (0.933) με ~τις μισές παραμέτρους — το όφελος των explicit frequency features αναμένεται μεγαλύτερο σε υψηλότερη ανάλυση από τα 32×32 .




Εικ. 5 — Παραδείγματα εικόνων που ταξινομούνται λάθος από όλους τους αλγορίθμους.

4. Νευρωνικά Δίκτυα

Q2.1 — MLP Baseline

Αρχιτεκτονική: $\text{flatten } 3.072 \rightarrow 512 \rightarrow 256 \rightarrow 2$ (BatchNorm, ReLU, Dropout 0.3, 1.706.754 παράμετροι). Adam, lr $1e-3$, 15 epochs. **Test accuracy 0.755 (F1 0.755)**. Οι καμπύλες δείχνουν **overfitting**: train accuracy ~ 0.90 ενώ validation ~ 0.77 .



Εικ. 6 — MLP: καμπύλες train loss και train/validation accuracy.

Q2.2 — MLP vs καλύτερος κλασικός

Το MLP σε raw pixels (0.755) είναι ισοδύναμο με τους handcrafted κλασικούς (HOG+SVM 0.765) και σαφώς κατώτερο από τον κλασικό σε CNN features (SVM+CNN 0.906). Ένα MLP πάνω στα CNN features φτάνει **0.900**. Συμπέρασμα: η **πολυπλοκότητα του MLP δεν δικαιολογείται σε raw pixels** — αγνοεί τη χωρική δομή. Η αξία προκύπτει μόνο με καλή αναπαράσταση εισόδου.


Q2.3 — CNN from scratch & regularization

Αρχιτεκτονική: 3 conv blocks (32 → 64 → 128, Conv → BatchNorm → ReLU → MaxPool) + FC 128 + Dropout, 356.226 παράμετροι, 20 epochs. **Test accuracy 0.933 (F1 0.933).**

Quick ablation (10 epochs) στο test set:

Config	Test Acc	F1-macro
baseline (no BN/Dropout/DA)	0.915	0.915
+ BatchNorm	0.908	0.908
+ Dropout 0.5	0.913	0.912
+ Data Augmentation	0.905	0.905

Σε αυτό το run οι διαφορές είναι **μικρές (≤ 1 μονάδα)** και καμία τεχνική regularization δεν ξεπέρασε το baseline στο σύντομο ablation — ένδειξη ότι σε αυτό το μέγεθος το μοντέλο δεν υπερπροσαρμόζεται αρκετά ώστε να ωφεληθεί. Σταθερό εύρημα: το **data augmentation ήταν συστηματικά η χαμηλότερη παραλλαγή (0.905)**, πιθανώς γιατί flip/rotation/jitter **αλλοιώνουν τα ίδια τα generative artifacts** που διαχωρίζουν real/fake. Σημειώνεται ότι το πλήρες CNN (με BatchNorm+Dropout+augmentation, 20 epochs) έφτασε 0.933, υψηλότερα από το σύντομο ablation.



Εικ. 7 — Custom CNN: καμπύλες train loss και train/validation accuracy.

Q2.4 — MLP vs CNN & inductive bias

Το CNN (0.933, 356k params) υπερτερεί δραματικά του MLP (0.755, 1.7M params) — **καλύτερη ακρίβεια με $\sim 5\times$ λιγότερες παραμέτρους**. Οφείλεται στο inductive bias: **locality**, **weight sharing** και **translation invariance**. Στο CIFAKE τα generative artifacts είναι τοπικά μοτίβα που ένα conv φίλτρο εντοπίζει αποδοτικά σε οποιαδήποτε θέση.

5. Transfer Learning & Few-Shot

Q3.1 — Transfer learning: full vs frozen

Μοντέλο	Στρατηγική	Test Acc	Training Time	#Trainable
ResNet18	full	0.942	91.2 s	11.177.538
ResNet18	frozen	0.852	105.6 s	1.026
EfficientNet-B0	full	0.958	89.1 s	4.010.110
EfficientNet-B0	frozen	0.865	105.4 s	2.562

Q3.2 — Ποια στρατηγική κερδίζει & ρόλος του freezing

Καλύτερο: **EfficientNet-B0 full fine-tuning (0.958)**, λίγο πάνω από ResNet18 full (0.942). Το **full fine-tuning υπερτερεί του frozen** κατά ~9 μονάδες, γιατί προσαρμόζει όλο το backbone στο ειδικό task. **Παρατήρηση για το freezing:** μειώνει τις trainable παραμέτρους κατά ~4 τάξεις μεγέθους (σε ~1–2,5 χιλιάδες), αλλά **ο wall-clock χρόνος δεν μειώθηκε** (μάλιστα ήταν ελαφρώς μεγαλύτερος, 105 s έναντι 89 s) — το forward pass μέσα από το backbone παραμένει. Το όφελος του frozen είναι μνήμη/αποθήκευση και ανθεκτικότητα σε overfitting, όχι ταχύτητα.


Q3.3 — Few-shot data efficiency

Μοντέλο/Στρατηγική	Full Data	10-shot	5-shot
EfficientNet-B0 / full	0.958	0.668	0.513
ResNet18 / full	0.942	0.710	0.619

Πιο **data-efficient** είναι το **ResNet18**: παρότι το EfficientNet νικά στο full data, στο few-shot το ResNet18 πέφτει λιγότερο (5-shot 0.619 vs 0.513). Το μεγαλύτερο EfficientNet υπερπροσαρμόζεται πιο εύκολα σε ελάχιστα δείγματα.

Q3.4 — Confusion matrix 5-shot

Στο καλύτερο 5-shot config (ResNet18/full, 0.619) η σύγχυση αυξάνεται και προς τις δύο κατευθύνσεις σε σχέση με το full-data· με 5 δείγματα ανά κλάση το όριο απόφασης είναι ασταθές.



Εικ. 8 — Confusion matrix στο 5-shot σενάριο (καλύτερο config).

Q3.5 / Q3.6 — Prototype classifier (Euclidean vs Cosine, vs transfer)

Regime	Prototype-Euclidean	Prototype-Cosine
10-shot	0.610	0.602
5-shot	0.581	0.583

Euclidean και Cosine είναι **ουσιαστικά ισοδύναμα** (διαφορές <0.01). Στο few-shot, ο prototype classifier **έχασε από το fine-tuning** (5-shot: prototype 0.583 vs ResNet18 fine-tune 0.619). Εξήγηση: ο ImageNet encoder δεν είναι εξειδικευμένος στο real/fake, οπότε οι μέσοι όροι embeddings δεν διαχωρίζουν καθαρά — ενώ το fine-tuning, ακόμη και με λίγα δείγματα, μετακινεί τα βάρη προς το ειδικό σήμα.

6. Self-Supervised Learning (SimCLR) & LoRA

Q4.1 — Ρόλος των augmentations στο contrastive learning

Στο SimCLR οι augmentations **ορίζουν τι θεωρείται «ίδιο»**: δύο augmented views της ίδιας εικόνας είναι το positive pair· χωρίς ισχυρές augmentations το NT-Xent έχει trivial λύση. Κατά Chen et al. (2020) ο συνδυασμός **random crop + color distortion** είναι ο πιο κρίσιμος.

Ιδιαιτερότητα CIFAKE: πολύ έντονο jitter/blur μπορεί να καταστρέψει τα ίδια τα generative artifacts — υπάρχει trade-off.

Q4.2 — SimCLR vs ImageNet transfer


Μέθοδος	Full Data	10-shot	5-shot
SimCLR (linear eval)	0.868	—	—
SimCLR (fine-tuned)	0.909	0.703	0.516*
ImageNet transfer (EfficientNet/full)	0.958	0.668	0.513

Στο full-data το ImageNet transfer (0.958) υπερτερεί του SimCLR (0.909) — αναμενόμενο, αφού το SimCLR εκπαιδεύτηκε σε 7.000 εικόνες/30 epochs. Όμως στο **10-shot το SimCLR (0.703) είναι ανταγωνιστικό** με το καλύτερο transfer (ResNet18 0.710) και καλύτερο από το EfficientNet (0.668) — ένδειξη ότι η domain-specific self-supervised αναπαράσταση βοηθά σε low-label καθεστώτα.

*** Ανωμαλία**: το SimCLR 5-shot έδωσε 0.516 ($\approx$ τύχη), πολύ χαμηλότερα από το 10-shot. Αυτό υποδηλώνει αστάθεια/collapse του few-shot fine-tuning σε εκείνο το run (frozen encoder, ελάχιστα δείγματα, συγκεκριμένο seed). Συνιστάται re-run με πολλαπλά seeds· αναφέρεται ως instability.

Q4.3 / Q4.4 — Embeddings & data regime

Στα t-SNE/UMAP των SimCLR embeddings διακρίνεται μερικός διαχωρισμός των δύο κλάσεων (λιγότερο καθαρός από τα ImageNet CNN features). Το SimCLR προσφέρει το μεγαλύτερο σχετικό όφελος στο **10-shot**, όπου είναι ισάξιο των transfer μεθόδων· στο 5-shot το αποτέλεσμα ήταν ασταθές.



Εικ. 9 — t-SNE και UMAP των SimCLR embeddings (test set).

Q4.5 — Full fine-tuning vs LoRA (ViT-B/16)

Μέθοδος	Trainable (M)	Trainable (%)	Test Acc	Train Time
Full fine-tuning	85.8	100.00 %	0.962	151 s
LoRA (r=8, query/value)	0.30	0.34 %	0.957	186 s

Q4.6 — Πόσο μικρή είναι η πτώση ακρίβειας;

Η πτώση είναι **μόλις 0.5 ποσοστιαία μονάδα** ($0.962 \rightarrow 0.957$), ενώ το LoRA εκπαιδεύει μόνο το **0.34% των παραμέτρων** ($\sim 290\times$ λιγότερες: 0.30M έναντι 85.8M). Δικαιολογείται απόλυτα από τα οφέλη. **Ειλικρινής παρατήρηση:** ο wall-clock χρόνος εδώ **δεν μειώθηκε** (186 s έναντι 151 s) — λόγω περισσότερων epochs (5 vs 3) και του overhead των adapters πάνω σε πλήρες forward/backward μέσα από το παγωμένο ViT. Το πραγματικό όφελος του LoRA είναι σε **trainable παραμέτρους, μνήμη και αποθήκευση** (πολλαπλά adapters πάνω σε ένα κοινό backbone), όχι στον χρόνο εκπαίδευσης σε ένα μόνο task.

Q4.7 — Μαθηματική ιδέα του LoRA


Το LoRA αντικαθιστά την ενημέρωση ενός βάρους W με low-rank παραγοντοποίηση: $W = W_0 + B \cdot A$, όπου $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ και $r \ll \min(d, k)$ (εδώ $r=8$). Το αρχικό W_0 παγώνει και μαθαίνονται μόνο τα A , B , μειώνοντας τις trainable παραμέτρους κατά ~ 2 τάξεις μεγέθους. Λειτουργεί γιατί η **προσαρμογή σε νέο task έχει χαμηλό intrinsic rank** — η αλλαγή που χρειάζεται «ζει» σε έναν μικρό υποχώρο. **Δύο σενάρια όπου υπερτερεί:** (α) όταν χρειάζονται πολλά task-specific adapters πάνω σε ένα κοινό frozen backbone (τεράστια εξοικονόμηση αποθήκευσης), και (β) όταν η μνήμη GPU για fine-tuning πολύ μεγάλων μοντέλων είναι περιορισμένη (δεν χρειάζεται optimizer state για όλες τις παραμέτρους).

7. Ενιαίο Benchmark & Συμπεράσματα

Task 5.1 — Συγκεντρωτικός πίνακας (test accuracy)

Πέρα από τα μοντέλα της εκφώνησης, υλοποιήθηκαν δύο επιπλέον αρχιτεκτονικές (βλ. §9.7–9.8): μια **Dual-Branch Artifact-Aware CNN** (RGB + frequency/residual branch) και ένα **CLIP-probe** (frozen CLIP encoder + head). Περιλαμβάνονται στον πίνακα.

Μέθοδος	Full	10-shot	5-shot
Best handcrafted (HOG+SVM)	0.765	—	—
Best classical (CNN feats + SVM)	0.906	—	—
MLP (raw pixels)	0.755	—	—
MLP σε CNN features	0.900	—	—
Custom CNN	0.933	—	—
Dual-Branch Artifact-Aware CNN	0.935	—	—
Transfer ResNet18 / full	0.942	0.710	0.619
Transfer EfficientNet-B0 / full	0.958	0.668	0.513
Prototype (ResNet18 encoder)	—	0.610	0.583
SimCLR linear eval	0.868	—	—
SimCLR fine-tuned	0.909	0.703	0.516
CLIP-probe (frozen + head)	0.947	0.743	0.675
DINOv2-probe (frozen + head)	0.945	0.718	0.650
ViT-B/16 full fine-tune	0.962	—	—
LoRA (ViT-B/16)	0.957	—	—



Εικ. 10 — Συγκεντρωτικό benchmark: κατάταξη full-data (πάνω) και σύγκριση few-shot (κάτω). Με κόκκινο οι επιπλέον αρχιτεκτονικές (Dual-Branch, CLIP-probe, DINOv2-probe).

Q5.1 — Καταλληλότερη μέθοδος ανά σενάριο

- **(α) Πολλά labeled data:** ViT-B/16 full fine-tuning (0.962) — κορυφαίο· πολύ κοντά EfficientNet-B0 full (0.958) και LoRA (0.957). Το καλύτερο **χωρίς fine-tuning του backbone** είναι το CLIP-probe (0.947).
- **(β) 10 ανά κλάση:** CLIP-probe (0.743) — υπερτερεί όλων, πάνω από ResNet18/full (0.710) και SimCLR fine-tuned (0.703).
- **(γ) 5 ανά κλάση:** CLIP-probe (0.675) — και πάλι πρώτο, με μεγάλη διαφορά από ResNet18/full (0.619) και prototype (0.583).

Q5.2 — Κατάταξη υπολογιστικού κόστους (ελαφρύ → βαρύ)

Prototype (~μόνο embeddings) < Κλασικοί (CV με PCA, ~45 s) < MLP (~84 s) < Custom CNN (~136 s) < transfer full/frozen (~89–106 s) < ViT-B/16 / LoRA (~150–186 s) < SimCLR pretraining (~450 s). Παράγοντες κόστους: πλήθος trainable παραμέτρων, ανάλυση εισόδου (32 vs 224), batch size, epochs, και αν απαιτείται backward μέσα από όλο το backbone.

Q5.3 — ImageNet transfer vs self-supervised

ImageNet transfer: έτοιμες ισχυρές αναπαραστάσεις, γρήγορο, νικά στο full data (0.958). Μειονέκτημα: εξαρτάται από μεγάλο labeled dataset και δεν «ξέρει» το ειδικό real/fake σήμα. **Self-supervised (SimCLR):** δεν χρειάζεται ετικέτες, μαθαίνει domain-specific features, ανταγωνιστικό στο 10-shot. Μειονέκτημα: ακριβό pretraining, ευαισθησία στις augmentations και (όπως φάνηκε) πιθανή αστάθεια στο few-shot fine-tuning. **Foundation-model probes (CLIP, DINOv2):** frozen encoders + μικρό head πέτυχαν 0.947 (CLIP) και 0.945 (DINOv2) στο full data — σχεδόν ισόπαλα — και τα καλύτερα few-shot αποτελέσματα όλων. Το CLIP προηγείται οριακά και είναι πιο σταθερό στο few-shot (10-shot 0.743 ± 0.006 vs DINOv2 0.718 ± 0.031), με μηδενική εκπαίδευση backbone — δείχνοντας ότι οι αναπαραστάσεις foundation models κωδικοποιούν ήδη το διακριτικό σήμα και είναι εξαιρετικά data-efficient.

Q5.4 — LoRA vs full fine-tuning

Με βάση τα αποτελέσματα, το LoRA έχασε **μόλις 0.5 μονάδα** (0.957 vs 0.962) εκπαιδύοντας **0.34% των παραμέτρων**. Το trade-off accuracy/efficiency γέρνει **καθαρά υπέρ του LoRA** όταν μετράει η μνήμη/αποθήκευση ή χρειάζονται πολλά adapters πάνω σε κοινό backbone. Το full fine-tuning προτιμάται μόνο όταν επιδιώκεται η απόλυτη μέγιστη ακρίβεια και οι πόροι είναι άφθονοι.

Q5.5 — Future work

- Frequency-domain (FFT/DCT) και noise-residual (SRM) features — υλοποιήθηκε ως Dual-Branch Artifact-Aware CNN (0.935)· επέκταση σε υψηλότερη ανάλυση όπου τα frequency fingerprints είναι πλουσιότερα.
- Έλεγχος γενίκευσης σε νεότερα generative μοντέλα (SD 2.1/3, Midjourney) — cross-generator robustness.
- Σταθεροποίηση του few-shot (πολλαπλά seeds, lr scheduling) και μεγαλύτερο SimCLR (batch/epochs, πλήρες dataset).
- Grad-CAM/ερμηνευσιμότητα για να εντοπιστεί πού «κοιτάζει» το δίκτυο· ensembles handcrafted + deep features.

8. Συνολική Ανάλυση Αποτελεσμάτων

1) Η αναπαράσταση κυριαρχεί. Η πιο σταθερή τάση: η ποιότητα των features καθορίζει την επίδοση περισσότερο από την πολυπλοκότητα του ταξινομητή. Από handcrafted (~0.66–0.77) → CNN features + κλασικός (~0.91) → end-to-end deep (0.93–0.96). Το ίδιο φαίνεται στο MLP-σε-CNN-features (0.900) έναντι MLP-σε-raw-pixels (0.755).

2) Σαφής ιεραρχία deep > classical > handcrafted. Κορυφή: ViT-B/16 (0.962), EfficientNet-B0 full (0.958), LoRA (0.957). Το custom CNN (0.933) είναι ήδη πολύ ανταγωνιστικό με ελάχιστες παραμέτρους, δείχνοντας ότι το inductive bias των CNN ταιριάζει στο πρόβλημα.

3) Το LoRA επιβεβαιώνει το low-rank adaptation. Πέτυχε 0.957 με 0.34% των παραμέτρων — πρακτικά ισόπαλο με το full fine-tuning (0.962). Δείχνει ότι η προσαρμογή ενός μεγάλου ViT σε αυτό το task έχει χαμηλό intrinsic rank.

4) Τα foundation-model probes είναι ο νικητής σε αποδοτικότητα. Frozen CLIP και DINOv2 + μικρό head έδωσαν 0.947 και 0.945 (full) — σχεδόν ισόπαλα — και **τα καλύτερα few-shot αποτελέσματα όλων** (CLIP 10-shot 0.743, 5-shot 0.675), χωρίς καμία εκπαίδευση backbone. Το CLIP ήταν οριακά καλύτερο και πιο σταθερό στο few-shot από το DINOv2. Το ότι ακόμη και ένα linear probe φτάνει 0.937 (CLIP) σημαίνει ότι τα features είναι σχεδόν γραμμικά διαχωρίσιμα για real/fake — η αναπαράσταση κωδικοποιεί ήδη το σήμα.

5) Η artifact-aware αρχιτεκτονική ισοφαρίζει με λιγότερες παραμέτρους. Το Dual-Branch (RGB + frequency/residual) πέτυχε 0.935 — ίσο με το custom CNN (0.933) αλλά με ~τις μισές παραμέτρους — χωρίς όμως να το ξεπερνά σημαντικά· στα 32×32 τα explicit frequency features προσφέρουν περιορισμένο επιπλέον σήμα.

6) Το few-shot είναι δύσκολο. Όλες οι μέθοδοι πέφτουν σημαντικά στο 5-shot (0.51–0.68), γιατί το σήμα real/fake είναι λεπτό. Αναδεικνύονται οι data-efficient προσεγγίσεις — με πρώτο το CLIP-probe και μετά το ResNet18 (αντί του μεγαλύτερου EfficientNet).

7) Αντι-δισαιθητικά ευρήματα & διακύμανση. (i) Στο σύντομο ablation καμία regularization δεν ξεπέρασε το baseline, με το data augmentation σταθερά χαμηλότερο — πιθανώς γιατί αλλοιώνει τα artifacts. (ii) Ο prototype classifier έχασε από το few-shot fine-tuning, λόγω μη εξειδικευμένου ImageNet encoder. (iii) Το SimCLR few-shot έδειξε υψηλή διακύμανση (5-shot collapse στο 0.516) — υπενθύμιση ότι τα few-shot αποτελέσματα χρειάζονται πολλαπλά seeds.

8) Πρακτικό συμπέρασμα. Για ανίχνευση AI-generated εικόνων με άφθονα δεδομένα, ένα fine-tuned pretrained δίκτυο (ViT/EfficientNet) ή LoRA δίνει τη μέγιστη ακρίβεια· όταν όμως μετράει το κόστος ή τα δεδομένα είναι λίγα, ένα **CLIP-probe** (frozen encoder + linear head) είναι η πιο αποδοτική επιλογή — σχεδόν κορυφαία ακρίβεια και κορυφαία data-efficiency με ελάχιστο κόστος.

9. Περιγραφή Αρχιτεκτονικών

Αναλυτική περιγραφή των αρχιτεκτονικών, με τη σειρά των επιπέδων και τις υπερπαραμέτρους εκπαίδευσης.

9.1 MLP Baseline (Task 2.1)

Πλήρως συνδεδεμένο δίκτυο σε flattened raw pixels ($32 \times 32 \times 3 = 3.072$).

- Linear(3072 → 512) → BatchNorm1d(512) → ReLU → Dropout(0.3)

- Linear(512 → 256) → BatchNorm1d(256) → ReLU → Dropout(0.3)
- Linear(256 → 2) [output logits]

Παράμετροι: 1.706.754. **Εκπαίδευση:** Adam, lr 1e-3, CrossEntropy, 15 epochs, batch 128, χωρίς augmentation.

9.2 Custom CNN (Task 2.2)

Συνελικτικό δίκτυο από το μηδέν, 3 conv blocks σε 32×32 (το spatial μέγεθος υποδιπλασιάζεται σε κάθε block).

- Block 1: Conv2d(3 → 32, 3×3) → BatchNorm2d → ReLU → MaxPool2d(2) [32 → 16]
- Block 2: Conv2d(32 → 64, 3×3) → BatchNorm2d → ReLU → MaxPool2d(2) [16 → 8]
- Block 3: Conv2d(64 → 128, 3×3) → BatchNorm2d → ReLU → MaxPool2d(2) [8 → 4]
- Classifier: Flatten(2048) → Dropout(0.25) → Linear(2048 → 128) → ReLU → Dropout(0.25) → Linear(128 → 2)

Παράμετροι: 356.226. **Εκπαίδευση:** Adam, lr 1e-3, 20 epochs, batch 128, με data augmentation.

9.3 Transfer Learning — ResNet18 & EfficientNet-B0 (Task 3.1)

ImageNet-pretrained backbones, αντικατάσταση μόνο του head για 2 κλάσεις. Είσοδος 224×224 + ImageNet normalization. Στρατηγικές **full** / **frozen**.

- ResNet18: fc → Linear(512 → 2). Trainable: 11.177.538 (full) / 1.026 (frozen).
- EfficientNet-B0: classifier[1] → Linear(1280 → 2). Trainable: 4.010.110 (full) / 2.562 (frozen).

Εκπαίδευση: Adam, lr 1e-4 (full) / 1e-3 (frozen), 5–6 epochs, batch 64.

9.4 Prototype Encoder (Task 3.3)

Frozen ImageNet ResNet18 (fc = Identity → **512-d embeddings**). Prototype = μέσος όρος embeddings ανά κλάση· ταξινόμηση με πλησιέστερο prototype (Euclidean / Cosine). Δεν εκπαιδεύονται βάρη.

9.5 SimCLR (Task 4.1)

Self-supervised contrastive framework· δύο augmented views ανά εικόνα.

- Encoder: ResNet18 (τυχαία αρχικοποίηση), fc = Identity → 512-d.
- Projection head (2 FC): Linear(512 → 512) → ReLU → Linear(512 → 128).
- Augmentations: RandomResizedCrop, HorizontalFlip, ColorJitter (p=0.8), RandomGrayscale (p=0.2), GaussianBlur (p=0.5).
- Loss: NT-Xent ($\tau = 0.5$). Εκπαίδευση: Adam, lr 3e-4, batch 512, 30 epochs, ανάλυση 96×96, mixed precision (AMP).

Αξιολόγηση: (1) linear evaluation σε frozen embeddings· (2) fine-tuning full· (3) few-shot fine-tuning.

9.6 ViT-B/16 & LoRA (Task 4.2)

Vision Transformer (google/vit-base-patch16-224, ~86M παράμετροι): patches 16×16 (196 tokens), 12 encoder layers, hidden 768, 12 attention heads, head 2 κλάσεων.

- Full fine-tuning: 85.8M trainable (100%) → test 0.962.

- LoRA: $r = 8$, $\alpha = 16$ στις query/value projections, dropout 0.1, εκπαιδεύσιμο classification head $\rightarrow$ 0.30M trainable (0.34%) $\rightarrow$ test 0.957.

Εκπαίδευση: Adam, lr $5e-5$ (full) / $1e-4$ (LoRA), batch 64, είσοδος 224×224 .

9.7 Dual-Branch Artifact-Aware CNN (επιπλέον πείραμα)

Custom αρχιτεκτονική δύο κλάδων που συνδυάζει spatial και frequency/residual πληροφορία, με στόχο τα generative artifacts. Είσοδος 32×32 .

- Branch A (spatial): 3 conv blocks ($24 \rightarrow 48 \rightarrow 96$, Conv $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ MaxPool $\rightarrow$ Dropout2d) σε RGB $\rightarrow$ AdaptiveAvgPool $\rightarrow$ 96-d.
- Branch B (frequency/residual): είσοδος 7 καναλιών — high-pass residual ($x - \text{Gaussian-blur}$), 3 σταθερά SRM-inspired high-pass kernels, και FFT log-magnitude spectrum — μέσα από ίδιο conv stack $\rightarrow$ 96-d.
- Fusion: concat (192-d) $\rightarrow$ gated fusion ($f \cdot \text{sigmoid}(Wf)$) $\rightarrow$ Dropout(0.5) $\rightarrow$ Linear(192 $\rightarrow$ 128) $\rightarrow$ ReLU $\rightarrow$ Dropout(0.5) $\rightarrow$ Linear(128 $\rightarrow$ 2).

Παράμετροι: ~ 168.866 (τα Gaussian/SRM φίλτρα παγωμένα). **Εκπαίδευση:** AdamW (weight decay $5e-4$), cosine LR, label smoothing 0.05, flip-only augmentation, early stopping στο best validation. **Αποτέλεσμα:** test 0.935 (best-val 0.933).

9.8 CLIP-probe (επιπλέον πείραμα)

Frozen foundation-model probe. Ο encoder είναι **CLIP ViT-B/32** (openai), παγωμένος· εξαγονται 512-d image embeddings (είσοδος 224×224 , CLIP normalization). Πάνω τους εκπαιδεύεται μόνο ένα ελαφρύ head.

- Head (neural): StandardScaler $\rightarrow$ Linear(512 $\rightarrow$ 256) $\rightarrow$ BatchNorm $\rightarrow$ ReLU $\rightarrow$ Dropout(0.3) $\rightarrow$ Linear(256 $\rightarrow$ 2). Test 0.947.
- Linear probe (σύγκριση): Logistic Regression στα 512-d embeddings. Test 0.937.

Few-shot (linear probe, μέσος όρος 3 seeds): 10-shot 0.743 ± 0.006 , 5-shot 0.675 ± 0.033 — τα καλύτερα few-shot αποτελέσματα όλων των μεθόδων. Μηδενική εκπαίδευση backbone.

9.9 DINOv2-probe (επιπλέον πείραμα)

Όμοιο με το CLIP-probe, με encoder **DINOv2 ViT-S/14** (frozen), που δίνει 384-d embeddings (CLS token, είσοδος 224×224). Πάνω τους εκπαιδεύεται μόνο head.

- Head (neural): StandardScaler $\rightarrow$ Linear(384 $\rightarrow$ 256) $\rightarrow$ BatchNorm $\rightarrow$ ReLU $\rightarrow$ Dropout(0.3) $\rightarrow$ Linear(256 $\rightarrow$ 2). Test 0.945.
- Linear probe: Logistic Regression στα 384-d embeddings. Test 0.934.
- Few-shot (linear, 3 seeds): 10-shot 0.718 ± 0.031 , 5-shot 0.650 ± 0.056 .

CLIP vs DINOv2: σχεδόν ισόπαλα στο full data (0.947 vs 0.945)· το CLIP προηγείται οριακά και είναι αισθητά πιο σταθερό στο few-shot (μικρότερο std). Η αρχική υπόθεση ότι το DINOv2 θα υπερεβεί σε texture/artifacts δεν επιβεβαιώθηκε σε αυτό το dataset.